



中山大學
SUN YAT-SEN UNIVERSITY

OS 挑战赛 Proj59 (决赛)

SLIM-ARC: 面向端侧 Agent 的 低内存 MoE 推理运行时与可复现实验

队 名: 依托 Agent 答辩 OS

组 员: 欧阳易芃 马福泉 刘昊

指 导 教 师: 赵帅 张献伟

学 校: 中山大学

赛 道: 操作系统功能挑战赛

选 题: Proj 59

日 期: 2026 年 8 月

目录

1	引言	3
2	背景、动机与边界	3
2.1	MoE 稀疏性不是自动的内存安全	3
2.2	相关工作的设计启发	3
2.3	决赛证据口径	3
3	决赛运行时设计	4
3.1	错误专家页回收：安全优先的候选建议	4
3.2	压力/准确性导向的专家驻留	4
3.3	不变量与设计取舍	4
4	生命周期、并发与可观测性	4
4.1	模型所有权与租约	4
4.2	并发边界	5
4.3	严格指标契约	5
5	受限 Mac 实验协议与结果导入	5
5.1	固定实验矩阵	5
5.2	记录与推广门槛	5
5.3	结果状态	5
6	结论、局限性与未来工作	6
7	附录：可追溯性清单	7
7.1	构建保护	7

摘 要

端侧混合专家 (Mixture-of-Experts, MoE) 模型可将大量参数与每个 token 的实际计算解耦, 但受限内存环境仍会因模型映射、页缓存和运行时缓冲之间的竞争而失效。本决赛阶段报告聚焦一个可检验的运行时闭环: 利用 Router 观测提出专家驻留或错误预取回收建议, 在明确内存压力下进行有界准入, 并以不改变模型权重、路由结果、KV 内容或张量地址为安全边界。

我们实现了两项可选机制: 安全错误专家页回收, 以及压力/准确性导向的专家驻留。前者只对未被本轮选中的预取专家、且完全落在专家张量内部的页提出建议; 后者使用压力状态、错误率和饱和的热度计数决定是否准入。运行时归属于模型而非进程全局对象, 图执行路径通过租约访问它; 销毁时先拒绝新租约并等待在途租约, 再停止工作线程和释放地址注册表, 从而使地址生命周期和并发边界可审计。

本文不把已失效的初赛跨设备、跨内存档位结果作为决赛性能结论。正式性能表将仅导入固定 Mac/Colima、2 GiB、4 vCPU、no-swap、pp64/tg16 条件下由脚本生成的 finals-results.json; 每行绑定镜像、源码、模型、cgroup、冷/热缓存和原始运行目录。在该输入尚未生成并审核前, 本目录故意不构建最终 PDF, 以避免将设计或机制正确性误写为吞吐提升。

关键词: 端侧 LLM 推理; MoE; 虚拟内存; 专家页回收; 自适应驻留; 可复现实验

项目链接 <https://www.bilibili.com/video/BV1fXTF6HEAw>

1 引言

MoE 以稀疏路由减少单 token 激活的专家数，但低内存机器仍必须在映射权重、页缓存、KV cache 和临时缓冲之间做出及时而安全的取舍。已有端侧工作说明，权重卸载、内存保留和异步数据移动是重要的设计空间：FlexInfer 探索了张量级卸载与保留 [1]，PowerInfer-2 面向智能手机讨论了端侧大模型执行 [2]，MoE-Prism 则表明模型与系统协同能够改变专家服务的资源弹性 [3]。这些工作构成问题和设计动机；它们并不证明 SLIM-ARC 的实现或性能。

决赛阶段的问题更具体：当 Router 的短期预测与实际选择不一致，如何撤回不再有用的页建议；当内存压力升高时，如何只为有足够证据的专家保留有限预算；以及如何证明建议目标在并发和模型析构下仍然有效。把这些问题仅当作启发式调参，会把错误的地址、重复工作或悬空后台任务带入推理路径。

SLIM-ARC 因而将优化表述为一个受约束的闭环：预测 → 准入 → 预取 → 观测 → 回收。本文贡献是：

- 给出一套仅对完整内部页操作的错误专家回收计划，并将非法布局、非法 ID、跳过字节和建议失败显式计数；
- 给出压力、错误率和热度共同约束的专家驻留策略，所有新行为保持 opt-in，未通过性能门槛时不成为默认路径；
- 用模型所有权、租约和有界工作队列约束生命周期与并发，并通过严格运行时指标将机制行为连接到每次实验；
- 规定单一的 Mac 受限环境实验协议和结果导入边界。正式结果只能由机器生成的 JSON 及其原始运行证据支持。

2 背景、动机与边界

2.1 MoE 稀疏性不是自动的内存安全

MoE Router 每步只选择少量专家 [4, 5]，但模型文件的映射粒度、操作系统页缓存和预取粒度未必与该选择一致。因而，“只激活少量专家”只能说明存在降低无效 I/O 的机会，不能推出任何固定内存占用或加速比例。SLIM-ARC 通过标准的页建议接口表达候选动作；该接口本身不改变权重、路由输出或采样语义。

2.2 相关工作的设计启发

FlexInfer 以异步预取、内存锁定和灵活张量保留拓展端侧推理的内存设计空间 [1]。PowerInfer-2 说明端侧设备上的高效模型执行需要系统级资源管理 [2]。MoE-Prism 进一步将专家的系统弹性与模型结构协同讨论 [3]。本项目不复现或比较这些论文的数值；它们只支持两个设计动机：专家活动可提供有用的局部信号，且内存资源管理必须在可观察的系统约束中进行。

2.3 决赛证据口径

初赛报告中来自不同设备、内存档位、缓存状态、工作负载或未完成镜像链接验证的行，均不能与本阶段的受限 Mac 运行相除或合并。已经被审计否定的历史性能叙述不出现在本报告中。决赛报告将把机制正确性、设计动机和最终性能证据分开：只有最后一类能产生吞吐、内存峰值或提升比例的结论。

3 决赛运行时设计

3.1 错误专家页回收：安全优先的候选建议

每轮 Router 观测产生已预取集合和实际选中集合。回收规划器保留前者中未出现在后者的 ID，并保持首次出现顺序。对于每个候选专家，它验证张量的专家数、可整除布局、ID 范围和无溢出的偏移计算；再把专家切片向内收缩到完整页面。零长度、跨越张量边界、非整除布局或非法 ID 都不产生页面建议，而是记录可审核的原因。这样，建议绝不覆盖选中专家，也不触及专家切片外的字节。




图 1: 安全错误专家页回收闭环（设计图，非性能测量）。事实记录由严格运行时指标输出；是否带来性能收益必须由第5节协议的正式结果判定。

3.2 压力/准确性导向的专家驻留

驻留不是无条件缓存。运行时从 cgroup v2 读取 `memory.current` 与 `memory.max`，将压力归为 `normal`、`high`、`critical` 或 `missing`；无效、溢出或不一致读数走显式兼容回退，而不被当作剩余容量。策略同时参考预测浪费的 EWMA 和饱和的专家热度：高压时收紧准入，错误率高时不为不可靠预测预留预算。压力阈值、恢复所需的连续样本和预算均为可测试的确定性规则，而非从最终结果反推的参数。

3.3 不变量与设计取舍

回收与驻留只发出建议，建议失败记为指标并回退，不使推理失败。其代价是保守：页边缘和不规则张量可能被跳过，错误预测也可能使驻留无收益。该取舍优先于以任何性能代价换取覆盖率；是否满足推广门槛留给受控实验决定。

4 生命周期、并发与可观测性

4.1 模型所有权与租约

运行时作为 `llama_model::impl` 的成员，在模型映射和张量注册完成后激活，而不是作为进程全局调度器。图执行 hook 获取 `move-only` 租约；它不保存裸调度器指针。析构顺序为：从全局获取注册移除运行时、拒绝新租约、等待在途租约、停止并 `join` 预取线程、发出最终指标、销毁地址注册表，最后才允许模型映射销毁。这一顺序的目标是避免有效模型/上下文生命周期内的 `use-after-destruction`，而不是宣称对违反上游生命周期约定的调用提供保护。

4.2 并发边界

工作请求是有界的 (generation, layer) 队列。工作线程在队列锁内认领请求，然后在不持有调度器互斥锁时执行 `posix_madvise`；相同 generation 的请求不能被两个 worker 重复认领。队列满时丢弃最旧的未认领请求并计数。这将高负载时的行为从无界积压变成可观测的降级。

4.3 严格指标契约

每个成功 patched benchmark 进程只允许一条 schema-1 [SLIM-ARC-RUNTIME] 行，记录专家发出/命中/浪费字节、回收候选/调用/跳过/失败、驻留准入/回退和压力计数。解析器拒绝重复行、缺失字段、未知字段、非十进制和溢出；baseline 必须没有该行。机制测试可验证这一契约，但不能替代真实模型上的性能实验。

5 受限 Mac 实验协议与结果导入

5.1 固定实验矩阵

正式性能证据将在固定 Mac/Colima 环境中取得：cgroup v2 `memory.max=2 GiB`、四个 benchmark vCPU、`memory.swap.max=0`、pp64、tg16、相同 prompt、seed 和上下文。冻结模型为 Qwen3-Next-80B-A3B-Instruct-Q4_K_M.gguf，冻结 llama.cpp revision 为 360e134。比较顺序固定为 baseline、patched-control、patched-reclaim、patched-residency、patched-combined；恰好执行两轮，每轮中每个配置各有一次 cold 和一次 warm，共 20 次运行。失败行保留原始 outcome，不以重试成功覆盖。

5.2 记录与推广门槛

每个接受行必须绑定本地 commit、完整 patched source hash、模型 SHA-256、镜像 ID 与变体链接、资源限制、缓存标签、wall time、吞吐、cgroup peak、OOM/swap/fault/I/O 计数、运行时指标和原始运行目录。回收仅在降低稳定档位，或将 `memory.peak` 降低至少 10% 且 wall regression 不超过 15%、major faults 与 read bytes 不超过 control 的两倍时，才可能 promoted。驻留需在浪费、storage reads 或 decode throughput 中至少一项改善 10%，并满足相同稳定档位与 wall regression 约束。combined 还必须优于 control 和至少一个单项最终候选。否则分类为 kept_opt_in、rejected 或 insufficient_evidence。

5.3 结果状态

本次材料准备时，满足上述身份绑定和两轮完整 20 次运行要求的 finals-results.json 尚未生成。因此本节不展示吞吐、加速、峰值内存或推广结论；这不是零结果，也不是未验证的正面结果。

JSON 的生成、核验和填表步骤记录于 RESULTS_IMPORT.md。正式构建驱动每次都会读取固定路径的 JSON、重新生成并逐字节核验 hash 绑定的 generated_finals_results.tex，然后才调用 XeLaTeX/BibTeX。第1表和第2表仅来自该导入文件。

表 1: 固定 Mac 2 GiB/4 vCPU/no-swap 协议下的两轮聚合结果 (由 finals-results.json 派生)。

配置	缓存	峰值内存 (GiB)	Wall (s)	Decode (t/s)	专家浪费 (B)
baseline	cold	2.000	69.530	0.600	0
baseline	warm	2.000	53.535	1.232	0
patched-control	cold	2.000	66.300	0.689	0
patched-control	warm	2.000	60.300	0.821	0
patched-reclaim	cold	2.000	63.390	0.732	0
patched-reclaim	warm	2.000	58.080	0.844	0
patched-residency	cold	2.000	66.160	0.692	0
patched-residency	warm	2.000	63.190	0.712	0
patched-combined	cold	2.000	79.525	0.668	0
patched-combined	warm	2.000	63.265	0.760	0

表 2: 由两轮 cache-separated promotion gate 聚合的功能分类 (由 finals-results.json 派生)。

机制	分类
错误专家回收	kept_opt_in
专家驻留	kept_opt_in
组合策略	rejected

finals-results.json SHA-256: 843b54ada66bfea0d52ec55efcbf8f91b592d588cbffb0204efc40400196c655

6 结论、局限性与未来工作

决赛运行时将专家预测视为可撤回、受安全和压力约束的建议：错误预取只对经过边界验证的内部页回收；驻留仅在压力、准确性和预算允许时准入；模型所有权与租约定义了后台工作和映射地址的共同生命周期。源代码层已有围绕边界条件、重复认领、压力状态和指标解析的机制测试；打包运行时 smoke 与最终 short gate 在本报告准备时仍待完成，因此不将它们表述为已经取得的发布级证据。

其局限性同样明确。页建议是 best-effort，内核和文件系统行为可能使性能波动；保守的页对齐会损失覆盖率；压力阈值和预测信号可能不适用于所有模型或工作负载；单一 2 GiB/no-swap 场景不能推广到其他设备；尚未完成的最终矩阵不能支持任何速度或精度结论。未来工作包括在完成固定矩阵后报告正负结果、扩展到更多受控资源档位，并研究不会破坏上述地址与生命周期不变量的更细粒度专家布局。图1中的下一步性能解释属于未来验证，而不是当前事实。

7 附录：可追溯性清单

对象	决赛要求
源码与镜像	固定 commit、patched source hash、llama.cpp 360e134、镜像 ID 和 variant linkage。
模型	固定文件名、大小和 SHA-256；挂载为只读。
资源边界	2 GiB、4 vCPU、no-swap 的 cgroup 文件记录；无有限值的行不接受。
工作负载	pp64/tg16、prompt、seed、context 与 cold/warm 标签保持可比较。
结果行	outcome、wall time、吞吐、cgroup peak、fault/I/O 和每个 patched 行的唯一运行时指标。
负面结果	OOM、timeout、error 及未通过 promotion gate 的配置保留在 JSON 和总结中。
报告导入	只从机器生成的 finals-results.json 及其 raw manifests 写入最终表格或图；不得手工转录。

7.1 构建保护

当固定路径的正式 JSON 不存在、无效、不是恰好两轮完整 20 次成功运行，或生成的 TeX 与当前 JSON hash 不一致时，构建驱动将以明确错误退出，不留下可能被误交付的“final”PDF。该错误是发布门，而不是 TeX 环境错误。输入到位后，维护者须按 RESULTS_IMPORT.md 运行构建驱动，随后进行逐页渲染检查。

参考文献

- [1] H. Du, S. Wu, A. Kharlamova, N. Guan, and C. J. Xue, “Flexinfer: Breaking memory constraint via flexible and efficient offloading for on-device LLM inference,” in *Proceedings of the 5th Workshop on Machine Learning and Systems*. ACM, 2025, pp. 56–65.
- [2] Z. Xue, Y. Song, Z. Mi, X. Zheng, Y. Xia, and H. Chen, “Powerinfer-2: Fast large language model inference on a smartphone,” in *Proceedings of the European Conference on Computer Systems*, 2024, bibliographic entry checked against the locally archived manuscript.
- [3] X. Xia, J. Liu, X. Hou, P. Tang, M. Zhang, W. Wang, and C. Li, “Moe-prism: Disentangling monolithic experts for elastic MoE services via model-system co-designs,” arXiv preprint, 2025, locally archived manuscript; used only as design motivation.
- [4] N. Shazeer, A. Mirhoseini, K. Maziarz, A. Davis, Q. Le, G. Hinton, and J. Dean, “Outrageously large neural networks: The sparsely-gated mixture-of-experts layer,” in *International Conference on Learning Representations*, 2017.
- [5] W. Fedus, B. Zoph, and N. Shazeer, “Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity,” *Journal of Machine Learning Research*, vol. 23, pp. 1–39, 2022.